Report K-means clustering algorithm

台灣科技大學: 陳勁銘

StudentID: M10903311

實驗室:CFDLAB

前置作業

Ref

- Ref01
- Ref002
- GitHub
- 老師上課講義

To do list

All the needed data by the k-means algorithm should be stored in struct myData declared in kmeans.hpp

OpenMP

☑ Binding

資料整理

分類

- 非監督式學習
- 物以類聚

過程

1. 我們先設定好要分成多少(k)群。

- 2. 然後在feature space(x軸身高和y軸體重組出來的2維空間,假設資料是d維,則會組出d維空間)隨機 給k個群心
- 3. 每個資料都會所有k個群心算歐式距離(歐基李德距離Euclidean distance,其實就是直線距離公式, 從小學到大的那個距離公式,這邊距離當然也可以換成別種距離公式,但基本上都還是以歐式距離 為主)
- 4. 將每筆資料分類判給距離最近的那個群心。
- 5. 每個群心內都會有被分類過來的資料,用這些資料更新一次新的群心。
- 6. 一直重複3-5, 直到所有群心不在有太大的變動(收斂), 結束。

Discussiono1: Which data layout is faster? AOS or SOA?

Back up your discussions by conducting experiments by varying DIM, N, and K

data struct

```
struct myData {
    size_t DIM; // number of dimention
    size_t N; //number of point
    size_t K; // number of k clusters
    vector<float> pts; // 數量為 DIM * N
    vector<float> currentCentroids; // 數量為 k * DIM
    vector<float> oldCentroids; // 數量為 k * DIM
    vector<size_t> group; // 數量為K
};
```

主程式中:

myData data;//宣告一個 data 的 data struct

- 注意事項
 - currentCentroids 如果K在外圈 >> DIM要連續

main loop

我們最後輸出

```
std::cout << "\n"
<< argv[1] << ", "
```

讀資料區 readCSV

討論: 所有的vector使用at存取資料使得資料更為安全

- 1. AOS: coordinates of the same point are stored continuously.
 - x1, y1, z1, x2, y2, z2, x3, y3, z3, x4, y4, z4, ...

kmeansAOS.cpp

- 2. SOA: coordinates of the same dimension are stored continuously.
 - x1, x2, x3, x4, ... y1, y2, y3, y4, ... z1, z2, z3, z4, ... kmensSOA.cpp

```
inp.clear();
inp.seekg(0, inp.beg);
data.pts.resize(noLines*noAttributes);
for (size_t whichPt = 0; whichPt < noLines; ++whichPt) {
   inp.getline(buf, 4096);
   auto it = buf;
   for (size_t whichDim = 0; whichDim < noAttributes;++whichDim) {
     auto x = atof(it);
     data.pts[whichPt+whichDim*noLines] = x; ///SOA</pre>
```

```
while(*it!=',') ++it;
it++;
}
```

- 輸入中 外圈為 whichPt 内圈為 whichDim
 - AOS 友善
 - SOA 不友善

UpdateCentroids 中

我們決定了 currentCentroids 與 oldCentroids 的矩陣排法,可以觀察到外迴圈應該要放 count k 而 內迴圈則是 whichDim

```
data.currentCentroids.resize(data.K*data.DIM); // vector 大小data.currentCentroids[data.DIM*count_k+whichDim] // 輸入資料data.currentCentroids.at(data.DIM*count_k+whichDim) // 取出資料

data.oldCentroids.resize(data.K*data.DIM); // Vector 大小data.oldCentroids[count_k+whichDim*data.K] // 輸入資料data.oldCentroids.at(count_k+whichDim*data.K) // 取出資料
```

AssignGroups(迭帶區)

AssignGroups_parto1

以下這行可以省略,因為我們只需要比較大小,而**不需要知道真正的數值**

```
distance_sum_DIM = sqrt(distance_sum_DIM);
```

- 取點
 - 看到再取點時外迴圈為 whichPt , 內迴圈才是 whichDim
 - AOS 不友善 data.pts.at(whichPt+whichDim*data.N)
 - SOA 友善 data.pts.at(whichPt*data.DIM+whichDim)
- 寫入:
 - 寫入情況下,我們知道在C++中矩陣如果為 dis[whichPt][count_k] 則count為連續則要放內圈
 - 在這個迴圈中 SOA 與 AOS 都是優良的

AOS

AssignGroups_parto2

這裡也沒什麼問題,都為連續只不過之後要注意 dis_min 在平行化的情況下要設立私有變數 AOS 與 AOS

```
for (size_t whichPt = 0; whichPt < N_value; whichPt++)
{
    dis_min = FLT_MAX;</pre>
```

```
for (size_t count_k = 0; count_k < K_value; count_k++)
{
    if (dis_min > dis[whichPt][count_k] )
    {
        dis_min = dis[whichPt][count_k];
        data.group[whichPt] = count_k;
    }
    }
}
```

UpdateCentroids

- 取點
 - 看到再取點時 內迴圈為 whichPt , 外迴圈才是 whichDim
 - AOS 友善 data.pts.at(whichPt+whichDim*data.N)
 - SOA 不友善 data.pts.at(whichPt*data.DIM+whichDim)
- 寫入
 - data.oldCentroids 寫入檔案也是友善(count_k 在内迴圈)

SOA

檢查收斂 HasConverged

主迴圈中每一次也都有檢查所以我們也進行分析

- 寫入
- 讀值相當友善

AOS 與 SOA

```
for (size_t whichDim = 0; whichDim < DIM_value; whichDim++)
{
    for (size_t count_k = 0; count_k < K_value; count_k++)
    {
        tolerance_sum =+ std::abs(data.oldCentroids.at(count_k+whichDim*data.K) - data.cu
    }
}
for (size_t i =0; i <K_value*DIM_value; i++)
{</pre>
```

```
data.currentCentroids[i] = data.oldCentroids.at(i);
}
```

觀察到的有趣資訊

```
1. return 255; 就是 return -1;
```

- 2. #pragma once 可以取代以前 #if define....
 - 3. #include 為C++ 11的時間庫,提供計時,時鐘等功能。

加入OpenMP

有加入Fisrt Touch 的參數

- 1. data.pts // 刻意加入
- 2. dis // 自然加入

還沒

1.

readCSV(平行前後coding比較)

Part2 加入, First Touch

我們必須要想辦法在資料一開始就被安排在各個 thread 上面然後加入 binding 試看看 ,因為等等讀數值的時候沒有平行

```
#pragma omp parallel for schedule(static)
for (size_t whichPt = 0; whichPt < noLines; ++whichPt) {
          for (size_t whichDim = 0; whichDim < noAttributes;++whichDim) {
               data.pts[whichPt*noAttributes+whichDim] = 0.0;
          }
}</pre>
```

Part3 真正的讀數值

目前還沒計畫 IO區塊平行 這邊可能會因為上一個 Part2 中我們設計的記憶體關係,造成 Part3 比較慢,值得套論兩者關係

```
for (size_t whichPt = 0; whichPt < noLines; ++whichPt) {
   inp.getline(buf, 4096);
   auto it = buf;
   for (size_t whichDim = 0; whichDim < noAttributes;++whichDim) {
      auto x = atof(it);
      data.pts[whichPt*noAttributes+whichDim] = x;
      while(*it!=',') ++it;
      it++;
   }
}</pre>
```

InitializeCentroid

主要目標也是要讓疊帶的時候 First private

那就先跳過了

AssignGroups(迭代區)

Part1

```
for (size_t whichPt = 0; whichPt < N_value; whichPt++)
{
    for (size_t count_k = 0; count_k < K_value; count_k++)
    {
        distance_sum_DIM = 0;
        for (size_t whichDim = 0; whichDim < DIM_value; whichDim++)
        {
            distance_sum_DIM += pow((data.currentCentroids.at(count_k+whichDim*data.K)- c
        }
        // distance_sum_DIM = sqrt(distance_sum_DIM);
        dis[whichPt][count_k] = distance_sum_DIM;
    }
}

for (size_t whichPt = 0; whichPt < N_value; whichPt++)
{
    dis_min = FLT_MAX;
```

```
for (size_t count_k = 0; count_k < K_value; count_k++)
{
   if (dis_min > dis[whichPt][count_k] )
   {
      dis_min = dis[whichPt][count_k];
      data.group[whichPt] = count_k;
   }
}
```

這裡在做的事情其實很簡單,就是把每一個**獨立點**與現**有的形心距離**算出,存入矩陣 dis[whichPt][count_k]

所以我們可以很清楚的資料我們可以平行**各個點**,而形心(data.currentCentroids)為 唯獨入資料根據點來平行,整體程式是用 whichPT來平行所以還在思考要如何在這個大迴圈中一直需要的數值 data.currentCentroids 在各個thread中的記憶體,但因為大小很小所以可能已經可以在 cacheLine 裡面了

- 而這邊的一次會跑的迴圈大小為 DIM_value * K_value * N_value(可以平行) 可以說是最多計算的區域又有pow這個function
 - distance_sum_DIM += pow((<u>data.currentCentroids.at(</u>count_k+whichDim*data.K)-*<u>data.pts.at(</u>whichPtdata.DIM+whichDim)),2);

```
// 平行後
```

```
#pragma omp parallel for schedule(static) default(none) firstprivate(distance_sum_DIM,DIM
for (size_t whichPt = 0; whichPt < N_value; whichPt++)
{
    for (size_t count_k = 0; count_k < K_value; count_k++)
    {
        distance_sum_DIM = 0;
        for (size_t whichDim = 0; whichDim < DIM_value; whichDim++)
        {
            distance_sum_DIM += pow((data.currentCentroids.at(count_k+whichDim*data.K)- c
        }
        // distance_sum_DIM = sqrt(distance_sum_DIM);
        dis[whichPt][count_k] = distance_sum_DIM; //first polo
    }
}</pre>
```

```
#pragma omp parallel for schedule(static) default(none) firstprivate(N_value,K_value,dis_
for (size_t whichPt = 0; whichPt < N_value; whichPt++)
{
    dis_min = FLT_MAX;
    for (size_t count_k = 0; count_k < K_value; count_k++)
    {
        if (dis_min > dis[whichPt][count_k] )
        {
            dis_min = dis[whichPt][count_k];
            data.group[whichPt] = count_k;
        }
    }
}
```

跟前面意思一樣其實各個點不需要溝通

UpdateCentroids(迭代區)

- 整個程式的平行核心為 whichPt 所以我們要思考的是 在使用 #pragma omp for schedule(static) 切割for 迴圈的時候 到底需不需要等
 - 答案是不需要 我們可以把 總量 center_tem 與 總數 counter_tem 分開 後 用 reduction 相加 reduction(+:counter_tem[0:data.DIM:K_value]) reduction(+:center_tem[0:data.DIM:K_value])
 - 每一個dimention 又是獨立的,所以自己的thread做完就不用等了(如果你去等他其中一個 thread if 一直過 那大家不就都要等他,整個speedUP 變成會決定於 loadbalance 問題
 - 所以我們加入 nowait

```
// 平行後(AOS)
float center_tem[DIM_value*K_value] = {0.};
int counter_tem[DIM_value*K_value] = {0};

#pragma omp parallel default(none) firstprivate(K_value,N_value,DIM_value) shared(data) \
reduction(+:counter_tem[:]) reduction(+:center_tem[:]) proc_bind(spread)

{
    for (size_t whichDim = 0; whichDim < data.DIM; whichDim++)
    {
        for (size_t count_k = 0; count_k < K_value; count_k++)
        {
            #pragma omp for schedule(static) nowait
            for (size_t whichPt = 0; whichPt < N_value; whichPt++)
        {
```

這邊參考老師的

```
#include <iostream>
#include <omp.h>
#include <cstdlib>
using namespace std;
int main(int argc, char **argv)
    int votes[5]={0};
    argc>1 ? srand(atoi(argv[1])) : srand(1);  // 反正就是在產生亂數
    auto t1 = omp_get_wtime();
    #pragma omp parallel reduction(+:votes[:])
        for(int i=0; i<1000000; ++i)</pre>
            votes[ rand()%5 ] ++;
    t1 = omp_get_wtime() - t1;
    cout << "\nTotal: ";</pre>
    for(auto i: votes) cout << i << " ";</pre>
    cout << "\nTime spent: " << t1;</pre>
```

main loop

我們最後輸出

所以我們可以知道

```
1. K : argv[1]
```

2. convergence :: argv[2]

3. number of interaction :: it

4. Not include InitializeCentroid :: timer[0]

5. AssignGroups :: timer [1]

6. UpdateCentroids :: timer[2]

繪圖品

每筆資資料為五個取最好(時間最少)或是平均數值畫圖

- SpeedUP = \frac{Elapsed time of Sequential program}{Elapsed time of presently program}
- Sequential program 表示為平行前的程式

```
aos.exe: src/main.cpp kmeansAOS.o
  $(CC) $(CFLAGS) $< -o $@ kmeansAOS.o

soa.exe: src/main.cpp kmeansSOA.o
  $(CC) $(CFLAGS) $< -o $@ kmeansSOA.o

aos_sequential.exe: src/main.cpp kmeansAOS_sequential.o
  $(CC) $(CFLAGS) $< -o $@ kmeansAOS_sequential.o

soa_sequential.exe: src/main.cpp kmeansSOA_sequential.o

$(CC) $(CFLAGS) $< -o $@ kmeansSOA_sequential.o

$(CC) $(CFLAGS) $< -o $@ kmeansSOA_sequential.o</pre>
```

■ 為了跟其他人比較這次打算先使用 02 資料來做本次演算法

Information	
資料大小	
noAttributes	3
noLines	245057
使用的K	5
收斂值	1.00E-09
BindingThread	
OMP_PLACES	cores
OMP_PROC_BIND	spread
Firs-touch	ON

- [X]First touch
- [X]export OMP_PLACES=cores
- [X]export OMP_PROC_BIND=spread

目前看其他做平行計算的人都是取峰值,所以圖B表示The Best(時間最小)而圖片A則表示平均值,我們可以看到這台機器的電腦架構如下



可以看到下表格 Efficienc(SpeedUp / #threads)


■ 參考:圖: B.I

#threads	SpeedUp(Iterative)		Efficienc(Iterative)	
	AOS	SOA	AOS	SOA
2	1.900513777	1.908838825	0.950256888	0.954419413
4	3.668946068	3.710592267	0.917236517	0.927648067
8	6.946244363	7.004289656	0.868280545	0.875536207
16	12.97757978	13.0873584	0.811098736	0.8179599
32	14.58397577	14.53047347	0.455749243	0.454077296

我們的 Efficienc 隨著速 thread 超過 16 這台機器的 Core數量效率降低,但是儘管如此我們最在意的SpeedUp還是有從12.9些微提升到 14.58









■ 圖A.A

SpeedUp(AssignGroups, average)





14.13340228

7.343518596

1.811909118


3.642576552


圖B:Best

SOA

10.83162242

■ 圖B.I





■ 圖B.U

SOA

14.73685695



7.051325932

3.73400046

1.919353357

13.25647997

